

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

«Технологии разведочного анализа и обработки данных.»

Вариант № 15

Выполнил:
Ступницкий М.С.
группа ИУ5-64Б

Проверил:
Гапанюк Ю.Е.

Дата: 06.04.25

Дата:

Подпись:

Подпись:

2025 г.

Задание:

Номер варианта:

15

Номер задачи:

2. Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

Номер набора данных, указанного в задаче:

7. <https://www.kaggle.com/datasets/lava18/google-play-store-apps?select=googleplaystore.csv>

Дополнительные требования по группам:

Для студентов группы ИУ5-64Б, ИУ5Ц-84Б - для произвольной колонки данных построить график "Скрипичная диаграмма (violin plot)".

Ход выполнения:

```
Импорт библиотек

import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import *
from sklearn.impute import SimpleImputer, MissingIndicator
from sklearn.preprocessing import LabelEncoder
%matplotlib inline
sns.set(style="ticks")

[1]

Загрузка данных

data = pd.read_csv('googleplaystore.csv', sep=",")

[14]

Основные характеристики датасета

# Первые 5 строк датасета
data.head()

[15]
...
```

```

# Размер датасета - 10841 строка, 13 колонок
data.shape

[16]
... (10841, 13)

data.info()

[17]
... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 10841 entries, 0 to 10840
Data columns (total 13 columns):
#   Column          Non-Null Count  Dtype
---  -
0   App              10841 non-null  object
1   Category         10841 non-null  object
2   Rating           9367 non-null   float64
3   Reviews          10841 non-null  object
4   Size             10841 non-null  object
5   Installs         10841 non-null  object
6   Type             10840 non-null  object
7   Price            10841 non-null  object
8   Content Rating   10840 non-null  object
9   Genres           10841 non-null  object
10  Last Updated     10841 non-null  object
11  Current Ver      10833 non-null  object
12  Android Ver      10838 non-null  object
dtypes: float64(1), object(12)
memory usage: 1.1+ MB

total_count = data.shape[0]

[18]

data.isnull().sum() # пропуски в колонках Rating, Content Rating, Current Ver и Android Ver

[19]

```

```

# Преобразуем Installs в числовой формат (удаляем '+', ',' и переводим в int)
data = data[data['Installs'] != 'Free']
data['Installs'] = data['Installs'].str.replace('[+,]', '', regex=True).astype(int)

# Создаем новый признак: Popularity = Rating * log(Installs + 1)
data['Popularity_Score'] = data['Rating'] * np.log10(data['Installs'] + 1)

# Проверяем результат
data[['Rating', 'Installs', 'Popularity_Score']].head()

[21]
...

# Добавим искусственные пропуски для демонстрации, так как признак Rating целевой, в нем не будем заполнять пропуски
np.random.seed(42)
mask_quantitative = np.random.choice([True, False], size=len(data), p=[0.1, 0.9])

[23]

# добавляем пропуски в искусственно созданную колонку
data.loc[mask_quantitative, 'Popularity_Score'] = np.nan

[24]

print("Данные с пропусками:")
print(data.isnull().sum())

[25]
...
Данные с пропусками:
App              0
Category         0
Rating          1474
Reviews          0
Size             0
Installs         0
Type             1
Price            0
Content Rating   0
Genres           0
Last Updated     0

```

Обработка пустых значений

Категориальный признак

```
[28] temp_null_count = data[data['Current Ver'].isnull()].shape[0]
dt = str(data['Current Ver'].dtype)
temp_perc = round((temp_null_count / total_count) * 100.0, 2)
print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%'.format('Current Ver', dt, temp_null_count, temp_perc))
```

... Колонка Current Ver. Тип данных object. Количество пустых значений 8, 0.07%.

```
[29] # Обработка пропусков в категориальном признаке (мода)
mode_rating = data['Current Ver'].mode()[0]
print(f'Мода для Current Ver: {mode_rating}')
data['Current Ver'] = data['Current Ver'].fillna(mode_rating)

data[['Current Ver']]
```

... Мода для Current Ver: Varies with device

🔍 Command 🔍 Code 🔍 Notebook

Количественный признак

```
[30] temp_null_count = data[data['Popularity_Score'].isnull()].shape[0]
dt = str(data['Popularity_Score'].dtype)
temp_perc = round((temp_null_count / total_count) * 100.0, 2)
print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%'.format('Popularity_Score', dt, temp_null_count, temp_perc))
```

... Колонка Popularity_Score. Тип данных float64. Количество пустых значений 2441, 22.52%.

Violin plot отображает распределение данных, сочетая в себе box plot и ядерную оценку плотности (KDE).

```
[37] data_clean = data.dropna(subset=['Rating'])
plt.figure(figsize=(10, 6))
sns.violinplot(x='Type', y='Rating', data=data_clean)
plt.title('Распределение рейтинга по типу приложения')
plt.xlabel('Rating')
plt.show()
```

